

Презентация по лабораторной работе №7 по предмету Компьютерный практикум по статистическому анализу данных

СТУДЕНТ ГРУППЫ НФИБД-01-20 ЕВДОКИМОВ МАКСИМ МИХАЙЛОВИЧ (1032203019)

Цель работы

- ▶ Основной целью работы является специализированных пакетов Julia для обработки данных.

Задание 1

- ▶ Кластеризация:
- ▶ Загрузите через RDatasets данные `iris = dataset("datasets", "iris")`. Используйте Clustering.jl для кластеризации на основе k-средних. Сделайте точечную диаграмму полученных кластеров.
- ▶ Подсказка: вам нужно будет проиндексировать фрейм данных, преобразовать его в массив и транспонировать.

```
# 1
iris = dataset("datasets", "iris")
select!(iris, Not(:Species))
X = Matrix(iris)
X = X'

result = kmeans(X, 10, maxiter=10, display=:iter)
display(result)

scatter(iris.PetalLength, iris.PetalWidth, marker_z=result.assignments, color=:lightrainbow, legend=false)
```


Iters	objv	objv-change	affected
0	4.751000e+01		
1	3.375360e+01	-1.375640e+01	8
2	3.130117e+01	-2.452434e+00	9
3	2.974573e+01	-1.555441e+00	6
4	2.888679e+01	-8.589333e-01	6
5	2.812584e+01	-7.609596e-01	5
6	2.766506e+01	-4.607743e-01	2
7	2.745029e+01	-2.147678e-01	2
8	2.719512e+01	-2.551765e-01	3
9	2.710741e+01	-8.770634e-02	2
10	2.707821e+01	-2.919530e-02	0

K-means terminated without convergence after 10 iterations (objv = 27.078214869925517)

KmeansResult{Matrix{Float64}, Float64, Int64}([4.678947368421052 7.666666666666667 ... 7.411111111111111 5.4; 3.08421052631579 2.7999999999999994 ... 3.233333333333333 3.8923076923076922; 1.3789473684210527 6.733333333333333 ... 6.155555555555555 1.5076923076923079; 0.20000000000000007 2.1333333333333333 ... 2.0222222222222226 0.2692307692307693], [8, 1, 1, 1, 8, 10, 1, 8, 1, 1 ... 4, 4, 5, 4, 4, 4, 5, 4, 4, 5], [0.022746913580249384, 0.05639889196676506, 0.02008310249307499, 0.02113573407201841, 0.04496913580246087, 0.05414201183431544, 0.11639889196676734, 0.013858024691359105, 0.11218836565096524, 0.07376731301938833 ... 0.07747933884300551, 0.3192975206611379, 0.06935185185184878, 0.21747933884296344, 0.20293388429752213, 0.1565702479338711, 0.14046296296294258, 0.15202479338842068, 0.27111570247933514, 0.09268518518516089], [19, 3, 14, 22, 18, 22, 12, 18, 9, 13], [19, 3, 14, 22, 18, 22, 12, 18, 9, 13], 27.078214869925517, 10, false)

Решение задание 1: код и результат

Описание.



Решение задание 1: код и результат

Описание.

Задание 2.1

- ▶ Регрессия (метод наименьших квадратов в случае линейной регрессии):
 - ▶ Пусть регрессионная зависимость является линейной. Матрица наблюдений факторов X имеет размерность N на 3 `randn(N, 3)`, массив результатов N на 1, регрессионная зависимость является линейной. Найдите МНК-оценку для линейной модели.
- Сравните свои результаты с результатами использования `lsql` из `MultivariateStats.jl` (просмотрите документацию).
 - Сравните свои результаты с результатами использования регулярной регрессии наименьших квадратов из `GLM.jl`.

Подсказка. Создайте матрицу данных X_2 , которая добавляет столбец единиц в начало матрицы данных, и решите систему линейных уравнений. Объясните с помощью теоретических выкладок.

```
X = randn(1000, 3)
a0 = rand(3)
y = X * a0 + 0.1 * randn(1000)
```

```
# 2.1
X = randn(1000, 3)
a0 = rand(3)
y = X * a0 + 0.1 * randn(1000)

N = 1000
X2 = hcat(ones(N), X)

βhat1 = X2 \ y
yp = X2 * βhat1
mse1 = sqrt(sum(abs2.(y - yp)) / N)
println(βhat1)
println("среднеквадратичная ошибка (МНК в ручную): $(mse1)")

βhat2 = llsq(X, y; bias=false)
yp = X * βhat2
mse2 = sqrt(sum(abs2.(y - yp)) / N)
println(βhat2)
println("среднеквадратичная ошибка (МНК через llsq): $(mse2)")

X3 = DataFrame(a=y, b=X[1:end,1], c=X[1:end,2], d=X[1:end,3])
lmMSE = lm(@formula(a ~ b + c + d), X3)
βhat3 = GLM.coeftable(lmMSE).cols[1]
yp = X2 * βhat3
mse3 = sqrt(sum(abs2.(y - yp)) / N)
println(βhat3)
println("среднеквадратичная ошибка (МНК через GLM): $(mse3)")

println("Разница между ручным и llsq: ", round(mse2-mse1, digits=10),
        "\nРазница между ручным и GLM: ", round(mse3-mse1, digits=10))
```

```
[-0.000311618101701213, 0.8606564874922631, 0.4428678136955193, 0.30538050615671286]
среднеквадратичная ошибка (МНК в ручную): 0.0974939439453617
[0.8606705485972929, 0.44285323284271144, 0.30537073840766293]
среднеквадратичная ошибка (МНК через llsq): 0.09749443930530823
[-0.00031161810170119016, 0.8606564874922632, 0.4428678136955195, 0.30538050615671297]
среднеквадратичная ошибка (МНК через GLM): 0.0974939439453617
Разница между ручным и llsq: 4.954e-7
Разница между ручным и GLM: 0.0
```

Решение задание 2.1: код и результат

Описание.

Задание 2.2

- ▶ Регрессия (метод наименьших квадратов в случае линейной регрессии):
- ▶ Найдите линию регрессии, используя данные (X, y). Постройте график (X, y), используя точечный график. Добавьте линию регрессии, используя `abline!`. Добавьте заголовок «График регрессии» и подпишите оси x и y.

```
X = rand(100);  
y = 2X + 0.1 * randn(100)
```



```

# 2.2
X = rand(100)
y = 2X + 0.1 * randn(100)
Xh = hcat(ones(100), X)
lm2 = fit(LinearModel, Xh, y)
println(lm2)

Plots.plot(title="График регрессии", xlabel="x", ylabel="y", legend=:topleft)
Plots.plot!(X, predict(lm2), label="Regression Line")
Plots.scatter!(X, y, label="Data")
#=
Я не могу это просто какая-то фигня я 4 часа пытался понять что не так а она просто не работает
Plots.abline!(X, predict(lm2), label="Regression Line")
attempt to save state beyond implementation limit

a = GLM.coefstable(lm2).cols[1]
Plots.abline!(a[1], a[2], predict(lm2)[end], color=:green)

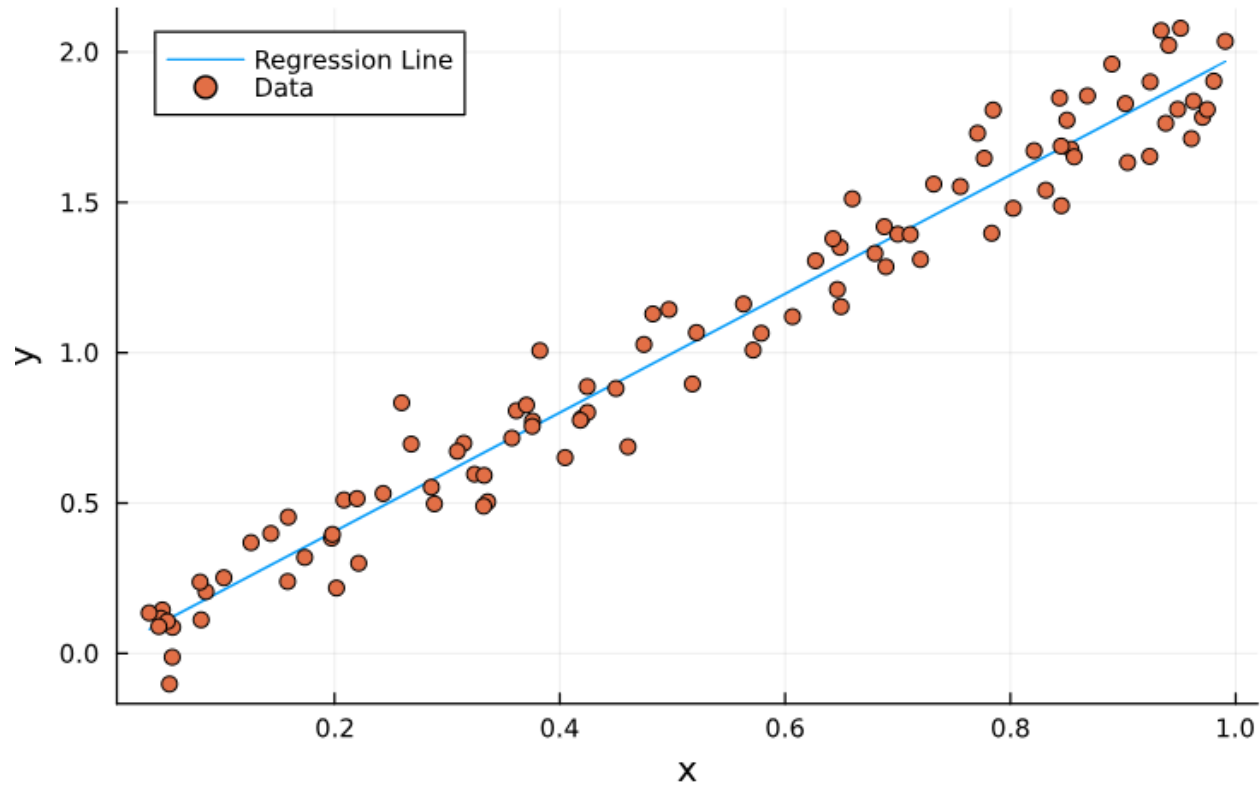
Он просто не рисует, от трёх переменных у него стек забивается, от lm у него просто град ошибок,
через раз у него ошибка границ при том что у меня чисто 3 одномерных массива из ровно 100 элементов,
при этом код его вообще не видит если не написать "Plots." перед ним, а документация это просто прелесть
просто 2 строчки: "abline!([plot,] a, b; kwargs...) Adds ax+b... straight line over the current plot, without changing the axis limits".
В официальных источниках вообще нет примеров, а интернет-примеры очень ситуативные и не всегда понятны.
Заменял просто на обычным plot по совету от сюда:
https://stackoverflow.com/questions/65895160/julia-how-to-find-best-fit-curve-equation-when-i-have-a-plot
=#

```

Решение задание 2.2: код

Описание.

График регрессии



Coefficients:

	Coef.	Std. Error	t	Pr(> t)	Lower 95%	Upper 95%
x1	0.0106298	0.0236228	0.45	0.6537	-0.0362489	0.0575086
x2	1.97581	0.0391357	50.49	<1e-71	1.89815	2.05348

Решение задание 2.2: результат

Описание.

Задание 3

- Описание модели ценообразования биномиальных опционов можно найти на стр. https://en.wikipedia.org/wiki/Binomial_options_pricing_model. Постройте траекторию возможных цен на акции:
 - S - начальная цена акции
 - T - длина биномиального дерева в годах
 - n - количество периодов
 - $h = T/n$ - длина одного периода
 - σ - волатильность акции
 - r - годовая процентная ставка
 - $u = \exp(r \cdot h + \sigma \cdot \sqrt{h})$
 - $d = \exp(r \cdot h - \sigma \cdot \sqrt{h})$
 - $p = (\exp(r \cdot h) - d) / (u - d)$

Задание 3.а

- ▶ Пусть $S = 100$, $T = 1$, $n = 10000$, $\sigma = 0.3$ и $r = 0.08$. Попробуйте построить траекторию курса акций. Функция `rand()` генерирует случайное число от 0 до 1. Вы можете использовать функцию построения графика из библиотеки графиков

```

# 3.a
function binomial_stock_price(S, T, n,  $\sigma$ , r)
    h = T/n
    u = exp(r * h +  $\sigma$  * sqrt(h))
    d = exp(r * h -  $\sigma$  * sqrt(h))
    p = (exp(r * h) - d) / (u - d)


    stock_prices = zeros(n+1)
    stock_prices[1] = S

    for i in 1:n
        for j in i:-1:1
            stock_prices[j+1] = u * stock_prices[j]
        end
        stock_prices[1] = d * stock_prices[1]
    end
    return stock_prices
end

S, T, n,  $\sigma$ , r = 100.0, 1.0, 10000, 0.3, 0.08
stock_prices = binomial_stock_price(S, T, n,  $\sigma$ , r)

plot(stock_prices, xlabel="Period", ylabel="Price", label="Stock Price Trajectory")

```




Решение задание 3.а: код и результат

Описание.

Задание 3.b

- ▶ Создайте функцию `createPath(S::Float64, r::Float64, sigma::Float64, T::Float64, n::Int64)`, которая создает траекторию цены акции с учетом начальных параметров. Используйте `createPath`, чтобы создать 10 разных траекторий и построить их все на одном графике.



```
# 3.b
function createPath(S::Float64, r::Float64, sigma::Float64, T::Float64, n::Int64)
    dt = T / n
    t = 0.0
    path = [S]

    for i in 1:n
        epsilon = randn()
        S = S * exp((r - 0.5 * sigma^2) * dt + sigma * sqrt(dt) * epsilon)
        t += dt
        push!(path, S)
    end
    return path
end

paths = [createPath(S, r, sigma, T, n) for i in 1:10]
plot(paths, title="Stock Price Paths", xlabel="Time", ylabel="Price", legend=false)
```


Решение задание 3.b: код и результат

Описание.

Задание 3.с

- ▶ Распараллельте генерацию траектории. Можете использовать `Threads.@threads`, `pmap` и `@parallel`.

Stock Price Paths (threads)



```
# 3.c
using Random
using Base.Threads

paths2 = []
@threads for i = 1:10
    push!(paths2, createPath(S, r, σ, T, n))
end

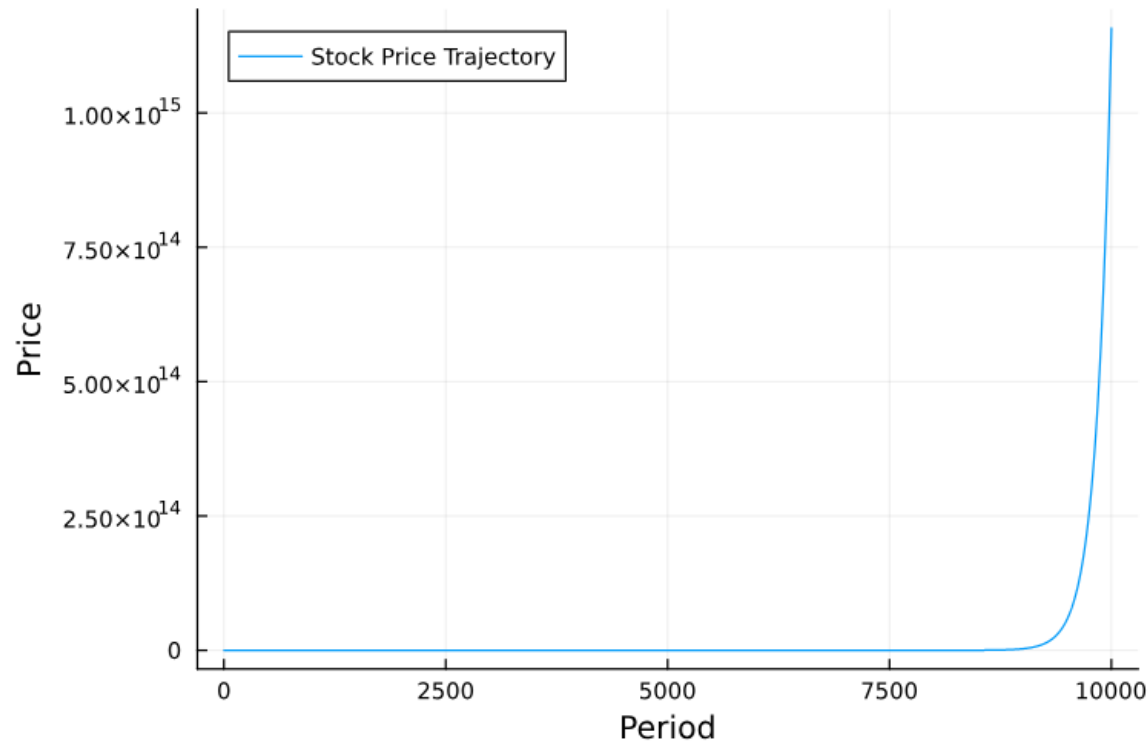
plot(paths2, title="Stock Price Paths (threads)", xlabel="Time", ylabel="Price", legend=false)
```

Решение задание 3.с: код и результат

Описание.

Задание 3.d

- ▶ Пусть $S = 100$, $T = 1$, $n = 10000$, $\sigma = 0.3$ и $r = 0.08$. Попробуйте построить траекторию курса акций. Функция `rand()` генерирует случайное число от 0 до 1. Вы можете использовать функцию построения графика из библиотеки графиков.



```
# 3.d
# =
А чем блин отличается этот пункт от "а"?
а) Пусть  $S = 100$ ,  $T = 1$ ,  $n = 10000$ ,  $\sigma = 0.3$  и  $r = 0.08$ . Попробуйте построить
   траекторию курса акций. Функция rand() генерирует случайное число от 0 до 1. Вы
   можете использовать функцию построения графика из библиотеки графиков.
д) Пусть  $S = 100$ ,  $T = 1$ ,  $n = 10000$ ,  $\sigma = 0.3$  и  $r = 0.08$ . Попробуйте построить
   траекторию курса акций. Функция rand() генерирует случайное число от 0 до 1. Вы
   можете использовать функцию построения графика из библиотеки графиков.
Ну ладно повторим :|
= #

S, T, n, sigma, r = 100.0, 1.0, 10000, 0.3, 0.08
stock_prices = binomial_stock_price(S, T, n, sigma, r)

plot(stock_prices, xlabel="Period", ylabel="Price", label="Stock Price Trajectory")
```

Решение задание 3.d: код и результат

Описание.

Заключение

- ▶ В ходе выполнения лабораторной работы были изучены основные принципы, типы и инструменты для изучения, обработки и анализа баз данных и их графического вывода.